

Commande floue et RL pour bras robotique 2 DDL

Rapport court destine a un enseignant-chercheur. L'objectif est de justifier la methode a adopter pour la suite du projet : combiner logique floue et apprentissage par renforcement, d'abord en Python, puis dans CoppeliaSim.

Le cahier des charges demandait une progression 2 DDL -> 3 DDL -> 6 DDL, avec formulation mathematique, comparaison PID/flou/RL et mise en evidence des notions RL : etat, action, reward, return, politique, valeur et Bellman.

L'hypothese defendue est que le flou/RL est plus prudent qu'un RL pur : le flou stabilise et rend la commande interpretable, tandis que le RL apprend une correction residuelle par interaction.

Rappel conceptuel : logique floue

La logique floue commande un systeme avec des concepts linguistiques : erreur negative, nulle, positive ; vitesse lente ou rapide ; commande faible ou forte.

Une variable n'appartient pas a un seul ensemble : elle active plusieurs fonctions d'appartenance avec des degres compris entre 0 et 1.

Dans ce projet, le controleur flou calcule une acceleration articulaire a partir de l'erreur et de sa variation.

$$e = q_desire - q$$

$$de/dt \approx (e(t) - e(t-dt)) / dt$$

$$q_ddot_flou = defuzzification(regles(e, de/dt))$$

Interet pour le projet : une politique lisible, stable, peu couteuse, qui peut servir de base a l'apprentissage.

Rappel conceptuel : apprentissage par renforcement

Le RL modelise le probleme comme un processus de decision de Markov.

$$\text{MDP} = (S, A, P, R, \gamma)$$

Un etat decrit la situation, une action modifie le systeme, un reward mesure la qualite de la transition, et gamma actualise les gains futurs.

$$G = r_0 + \gamma r_1 + \gamma^2 r_2 + \dots + \gamma^T r_T$$

$$V_{\pi}(s) = E_{\pi}[G \mid S_0 = s]$$

$$Q_{\pi}(s,a) = E_{\pi}[G \mid S_0 = s, A_0 = a]$$

$$V^*(s) = \max_a \sum_{s'} P(s'|s,a) [R(s,a,s') + \gamma V^*(s')]$$

$$Q(s,a) \leftarrow Q(s,a) + \alpha [r + \gamma \max_{a'} Q(s',a') - Q(s,a)]$$

Dans notre travail, le RL n'apprend pas directement tout le couple moteur : il apprend un residu autour d'un controleur stabilisant.

Modele du bras 2 DDL

Le bras est planaire, compose de deux segments de longueurs l_1 et l_2 et de deux articulations rotatives q_1, q_2 .

$$x = l_1 \cos(q_1) + l_2 \cos(q_1 + q_2)$$

$$y = l_1 \sin(q_1) + l_2 \sin(q_1 + q_2)$$

La dynamique utilisee dans la simulation a couples est :

$$M(q) \ddot{q} + C(q, \dot{q}) \dot{q} + G(q) + F \dot{q} = \tau$$

La commande a couple calcule convertit une acceleration desiree en couples moteurs :

$$\tau = M(q) \ddot{q}_{cmd} + C(q, \dot{q}) \dot{q} + G(q) + F \dot{q}$$

Cette formulation permet de comparer PID, flou et RL dans le meme environnement physique.

Architecture proposee : flou/RL residuel

La commande finale combine la politique floue et une correction apprise par Q-learning.

$$q_ddot_cmd = q_ddot_flou + q_ddot_RL_residuel$$

$$\tau = M(q) \, q_ddot_cmd + C(q, \dot{q}) \dot{q} + G(q) + F \dot{q}$$

L'etat continu du RL est :

$$x = (\text{erreur_q1}, \text{erreur_q2}, \dot{q1}, \dot{q2})$$

Chaque variable est projete sur negative, zero, positive, donc $3^4 = 81$ regles floues.


$$Q_flou(x,a) = \sum_i w_i(x) Q(\text{regle_i}, a)$$

$$\delta = r + \gamma \max_{a'} Q_flou(x',a') - Q_flou(x,a)$$

$$Q(\text{regle_i},a) \leftarrow Q(\text{regle_i},a) + \alpha w_i(x) \delta$$

Le superviseur de securite coupe le residu si la distance ne progresse plus, et revient au controleur flou seul.

Resultats : references PID et flou dynamiques




results\figures\step_06_pid_dynamic_2dof.png

PID dynamique : 131 pas, distance finale $1.38e-03$, couple moyen 13.66 N.m.


Flou dynamique : 360 pas, distance finale $5.23e-03$, couple moyen 13.85 N.m.

Le flou est plus lent ici, mais il converge et fournit une politique interpretable pour l'hybridation.



results\figures\step_07_fuzzy_dynamic_2dof.png

Resultat : Q-learning tabulaire




Le Q-learning retrouve une politique efficace sur le MDP discret.

La trajectoire apprise atteint la cible en 8 actions, comme la solution optimale calculée par value iteration.

Cette étape valide les notions RL fondamentales avant de passer à la dynamique.

Resultat : flou/RL sur cible de reference




Flou seul : 360 pas, distance finale 0.005227, couple moyen 13.853 N.m.

Flou + Q residuel : 269 pas, distance finale 0.005537, couple moyen 14.420 N.m.

Gain : 91 pas plus rapide, avec un effort moteur legerement plus eleve.

Resultats : generalisation et securite




Generalisation brute : flou seul 5/5, flou + Q 4/5. Le residu accelere quatre cibles mais degrade T4_high.

Version securisee : retour a 5/5 avec un gain moyen de 55 pas par rapport au flou seul.

Conclusion : le RL apporte une acceleration, mais le flou doit rester la politique de secours.

results\figures\step_11_fuzzy_residual_generalization_2dof.png



results\figures\step_12_fuzzy_residual_safe_generalization_2dof.png

Conclusion et suite recommandee

Le travail valide une progression coherente : modelisation 2 DDL, PID, flou, RL discret, RL dynamique residuel, puis flou/RL securise.

La methode a privilegier est l'hybridation flou/RL : elle est interpretable, plus stable qu'un RL pur, et assez flexible pour etre transferee vers CoppeliaSim.

Le resultat actuel ne prouve pas une superiorite definitive ; il montre un compromis scientifique exploitable : convergence plus rapide contre effort legerement plus eleve.

Prochaines etapes : entraînement multi-cibles, reward plus fin pour l'effort, estimation de confiance du residu, puis connexion a CoppeliaSim via la boucle interactive deja implementee.